EJERCICIOS: CERTAMEN #2A

(CERTAMEN #2)

Prof. Nibaldo Rodríguez A.

20 de octubre de 2026

EJERCICIOS: REDUCCIÓN DE DIMENSIONALIDAD vÍA MÉTODO (SLS)

Considerar un **Dataset** de N muestras con D variables explicativas dado por: $X \in \mathbb{R}^{N \times D}$.

Modelo para todas las muestras

$$
\begin{aligned}
Z &= XV, & V &\in \mathbb{R}^{D \times J}, \\
H &= f(Z), & H &\in \mathbb{R}^{N \times J}, \\
Y &= HU, & U &\in \mathbb{R}^{J \times D}.
\end{aligned}
$$

- V realiza la proyección no lineal hacia el espacio latente.
- U transforma las activaciones en una reconstrucción de las variables originales.
- J determina el número de coordenadas de la representación reducida.

ESTIMACIÓN DE PESOS: SLS

1. Fijada la proyección V, estimar los pesos lineales U mediante RLS.
2. Actualizar los pesos no lineales V mediante Descenso del Gradiente Regularizado

Función de Costo Regularizada

$$E = \frac{1}{2}\|X - Y\|_2^2 + \frac{\lambda}{2}\|U\|_2^2, \qquad \lambda \geq 0.$$

Función de Costo Regularizada

$$E = \frac{1}{2}\sum_{n=1}^{N}\sum_{d=1}^{D}(X_{nd} - Y_{nd})^2 + \frac{\lambda}{2}\sum_{j=1}^{J}\sum_{d=1}^{D}U_{jd}^2.$$

Se alterna la solución cerrada para U con la actualización iterativa de V.

Con V fijo, $H = f(XV)$ queda determinado. La condición de primer orden es

Función de Costo Regularizada

$$\frac{\partial E}{\partial U_{jd}} = \sum_{n=1}^{N} \sum_{q=1}^{D} \frac{\partial E}{\partial Y_{nq}} \frac{\partial Y_{nq}}{\partial U_{jd}} + \lambda U_{jd}.$$

Solución para la matriz de reconstrucción

$$U = (H^{\mathsf{T}} H + \lambda I_J)^{-1} H^{\mathsf{T}} X, \qquad U \in \mathbb{R}^{J \times D}.$$

- La regularización λ penaliza la magnitud de los pesos lineales.
- Para cada valor actualizado de V, se puede volver a estimar U en forma cerrada.

Con U fijo, la regla de la cadena completa Para cada peso V_{pj}, es:

Función de Costo (MSE):

$$\frac{\partial E}{\partial V_{pj}} = \sum_{n=1}^{N}\sum_{d=1}^{D}\sum_{r=1}^{J} \frac{\partial E}{\partial Y_{nd}} \frac{\partial Y_{nd}}{\partial H_{nr}} \frac{\partial H_{nr}}{\partial Z_{nr}} \frac{\partial Z_{nr}}{\partial V_{pj}}.$$

CASE #1 : $H = f(Z) = \cos(Z)$

$$\boxed{\frac{\partial E}{\partial V} = -\left[\left(U^{\top}(Y - X)\right) \odot \sin(Z)\right] X^{\top}}$$

- Para cada valor actualizado de U, se puede volver a estimar V.

Funciones Espacio Latante: H=f(Z)

1. **Seno:**
$$f(z) = \sin(z).$$
2. **Coseno:**
$$f(z) = \cos(z).$$
3. **Sigmoide logística:**
$$f(z) = \frac{1}{1 + \exp(-z)}.$$
4. **Tangente hiperbólica:**
$$f(z) = \tanh(z).$$

5. **Softplus:**

$$f(z) = \log(1 + \exp(z)).$$

6. **Unidad lineal sigmoidal (SiLU):**

$$f(z) = \frac{z}{1 + \exp(-z)}.$$

7. **Gaussiana:**

$$f(z) = \exp(-az^2), \quad \text{a:cte.}$$

8. **Cuadrática inversa:**

$$f(z) = \frac{1}{1 + z^2}.$$

Funciones Espacio Latante: H=f(Z)

9. **Multicuadrática:**

$$f(z) = \left(1 + \frac{z^2}{\sigma^2}\right)^{1/2}.$$

10. **Cuadrática inversa:**

$$f(z) = \left(1 + \frac{z^2}{\sigma^2}\right)^{-1}.$$

EJERCICIO: Regresión Softmax

Datos y etiquetas

- Se clasifican N muestras en K clases.
- Cada muestra contiene D características.
- Las etiquetas se representan mediante vectores one-hot.

$$x_n \in \mathbb{R}^D, \qquad t_n \in \{0,1\}^K, \qquad \sum_{k=1}^{K} t_{nk} = 1.$$

Estimación de Pesos vía Entropía Cruzada

Función de costo

- Se compara la distribución predicha Y con las etiquetas one-hot T.
- El entrenamiento busca minimizar el costo respecto de los pesos W.

$$E(W) = -\frac{1}{N}\sum_{n=1}^{N}\sum_{k=1}^{K} t_{nk}\log(p_{nk}).$$

Gradiente Entropía:

$$\frac{\partial E}{\partial W_{dj}} = ??$$

MÉTRICAS: Matriz de confusión y F-scores

Considerar los valores predicos por un modelo de regresión softmax, dados por:

$$\begin{bmatrix} 0{,}0012 & 0{,}0003 & 0{,}0011 & 0{,}0001 & 0{,}0000 & 0{,}0006 & 0{,}0002 & 0{,}0000 & 0{,}0000 & 0{,}0011 \\ 0{,}9493 & 0{,}9996 & 0{,}9920 & 0{,}0021 & 0{,}0000 & 0{,}0040 & 0{,}0004 & 0{,}0001 & 0{,}0000 & 0{,}9986 \\ 0{,}0388 & 0{,}0001 & 0{,}0069 & 0{,}9833 & 0{,}9999 & 0{,}9951 & 0{,}0004 & 0{,}0002 & 1{,}0000 & 0{,}0003 \\ 0{,}0107 & 0{,}0000 & 0{,}0000 & 0{,}0145 & 0{,}0000 & 0{,}0004 & 0{,}9990 & 0{,}9997 & 0{,}0000 & 0{,}0000 \end{bmatrix}$$

Considerar los valores deseados de clasificación, dados por:

$$\begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 1 & 1 & 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 1 & 1 & 0 & 0 \end{bmatrix}$$

MÉTRICAS: Matriz de confusión y F-scores

Calcular:

- Matriz de Confusión.
- F-scores.

Continuará. . .

Prof. Nibaldo Rodríguez A.

Continuará. . .

Prof. Nibaldo Rodríguez A.